Devoir final UE n°4 - Notebook Jupyter

Quentin Fouché

September 10, 2022

1 Description du jeu de données

[1]:
```
# (1) Import des packages
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.patches as mpatches
import seaborn as sns
import itertools
from statsmodels.formula.api import ols
import sys
!{sys.executable} -m pip install missingno
import missingno as msno
!{sys.executable} -m pip install upsetplot
from upsetplot import plot, from_indicators
import statsmodels.api as sm
from scipy import stats
import scikit_posthocs as sp
```

[2]:
```
# (2) Import du jeu de données "Biblio_synthese.csv"
biblio_orig = pd.read_csv(r"C:\Users\quent\Documents\DU Data Analyst 2022\UE␣
↪n°4 - Rédaction d'un rapport d'analyse\Jeux de données\Biblio_synthese.
↪csv", low_memory = False, encoding = "latin-1")
biblio = biblio_orig.copy(deep = True)
```

[3]:
```
# (3) Remplacement des caractères "Ã©" par "é" et des caractères "â" par "'"
biblio = biblio.replace(["Ã©", "â"], ["é", "'"], regex = True)
```

[4]:
```
# (4) Modification du titre des colonnes
biblio = biblio.rename(columns = {"section": "discipline", "numÃ©ro TEL":␣
↪"numéro TEL", "numÃ©ro citation": "numéro citation"})
```

[5]:
```
# (5) Renommage des types de référence
biblio["type"] = biblio["type"].replace(["chapter", "book",␣
↪"article-journal", "paper-conference", "thesis", "report", "webpage",␣
↪"manuscript", "patent", "interview", "motion_picture",␣
↪"personal_communication"], ["chapitre", "livre", "article", "papier de␣
↪conférence", "thèse", "rapport", "page web", "manuscrit", "brevet",␣
↪"interview", "film", "communication personnelle"], regex = True)
biblio.head()
```

[5]:
```
  discipline         numéro TEL  numéro citation      type  \
0          I  halshs-00005971v1                1  chapitre
1          I  halshs-00005971v1                1     livre
2          I  halshs-00005971v1                1       NaN
3          I  halshs-00005971v1                1   article
4          I  halshs-00005971v1                1     livre

                                                titre
0                                              Action
1  Mainstreaming Gender in the European Structura...
2  L'Européanisation saisie par son instrumenta...
3   Eléments pour une sociologie de la traduction Â»
4  [' L'agonie d'un laboratoire', 'La science...
```

[6]:
```
# (6) Inspection des variables
print(biblio.info())
print("")
print("_____________________________________________________________________")
print("")
print("Nombre de valeurs uniques par colonnes:")
print(biblio.nunique())
print("")
print("_____________________________________________________________________")
print("")
print("Disciplines:")
print(biblio["discipline"].unique())
print("")
print("_____________________________________________________________________")
print("")
print("Types de publication:")
print(biblio["type"].unique())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1821132 entries, 0 to 1821131
Data columns (total 5 columns):
 #   Column           Dtype 
---  ------           ----- 
 0   discipline       object
 1   numéro TEL       object
 2   numéro citation  int64 
 3   type             object
 4   titre            object
dtypes: int64(1), object(4)
memory usage: 69.5+ MB
None

---------------------------------------------------------------------

Nombre de valeurs uniques par colonnes:
discipline              11
numéro TEL           22889
```

```
numéro citation          1
type                    12
titre              1437703
dtype: int64
```

```
----------------------------------------------------------------------
```

```
Disciplines:
['I' 'II' 'III' 'IV' 'IX' 'pharmacie' 'V' 'VI' 'VII' 'VIII' 'X']
```

```
----------------------------------------------------------------------
```

```
Types de publication:
['chapitre' 'livre' nan 'article' 'papier de conférence' 'thèse' 'rapport'
 'page web' 'manuscrit' 'brevet' 'interview' 'film'
 'communication personnelle']
```

2 Étude des données manquantes

2.1 Répartition des données manquantes

[7]:
```
# (1) Calcul du pourcentage de valeurs manquantes par variable
biblio.isna().mean()*100
```

[7]:
```
discipline          0.000000
numéro TEL          0.000000
numéro citation     0.000000
type               14.808372
titre              10.566834
dtype: float64
```

[8]:
```
# (2) Représentation de la distribution des valeurs manquantes dans les deux␣
 ↪variables qui en contiennent
plt.rc("font", family = "Times New Roman", size = 12)
msno.matrix(biblio[["type", "titre"]].sort_values("type"), figsize = (17.5/2.
 ↪54, 9/2.54), fontsize = 12, label_rotation = 0)
plt.ylabel("Numéro de ligne", fontsize = 12)
plt.xlabel("Variables", fontsize = 12, labelpad = 12)
plt.tick_params(axis = "both", labelsize = 12)
gray_patch = mpatches.Patch(facecolor = '#383838', edgecolor = 'black', label␣
 ↪= 'Valeurs présentes')
white_patch = mpatches.Patch(facecolor = 'white', edgecolor = 'black', label␣
 ↪= 'Valeurs absentes')
plt.legend(handles = [gray_patch, white_patch], fontsize = 12, bbox_to_anchor␣
 ↪= (0.92, 1.30), frameon = False, ncol = 2)
plt.show()
```

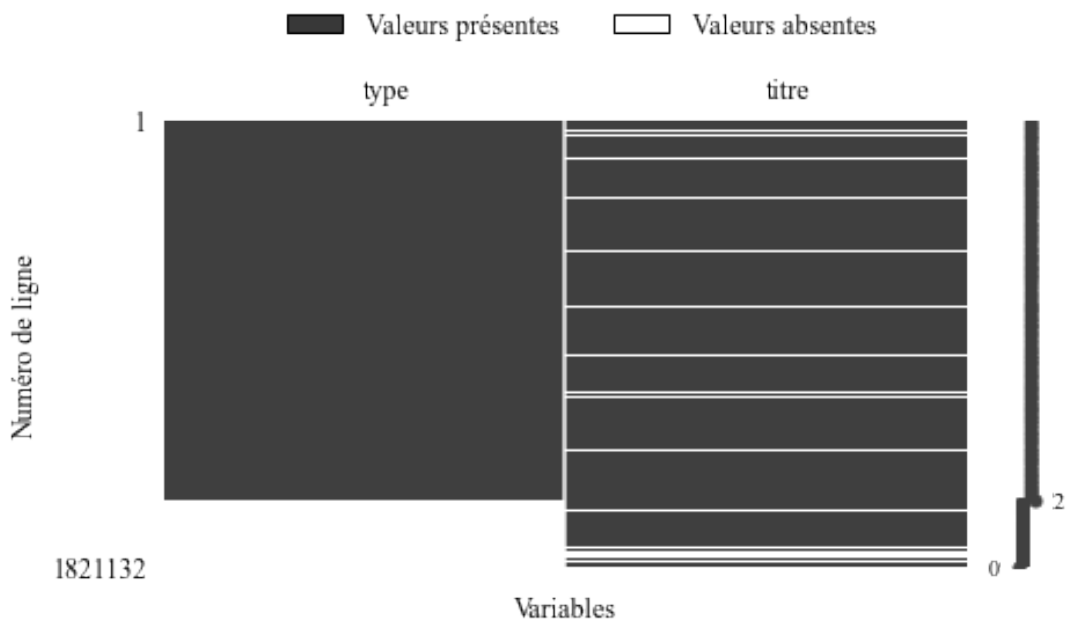

[9]:
```
# (3) Représentation de la distribution des valeurs manquantes dans chaque␣
↪combinaison de variables
plt.rc('font', family = 'Times New Roman', size = 12)
fig = plt.figure(figsize = (17.5/2.54, 9/2.54))
plot(from_indicators(indicators = pd.isna, data = biblio[["type", "titre"]]),␣
↪show_counts = True, fig = fig, element_size = None)
plt.show()
```

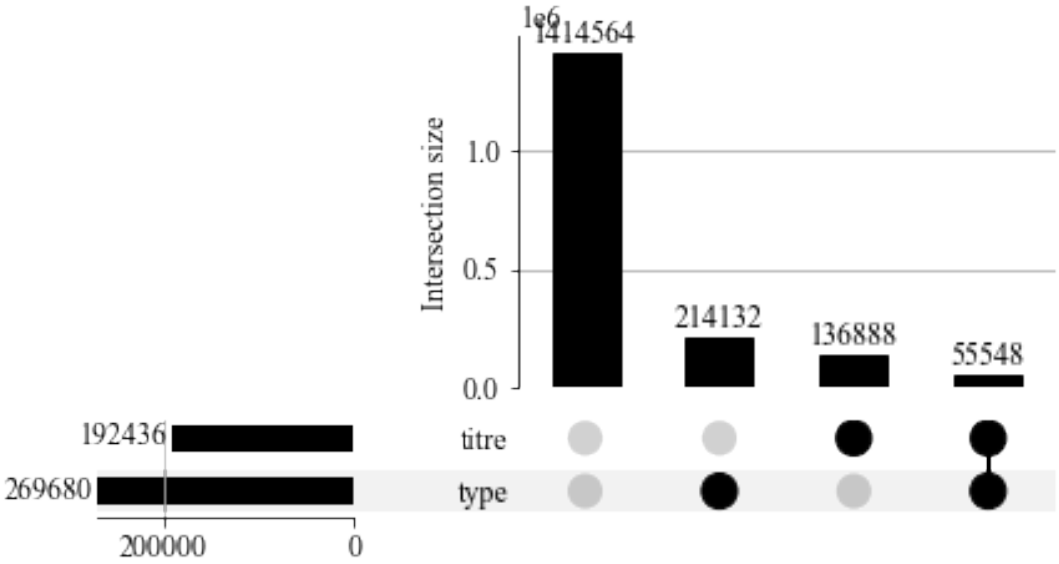

[10]:
```
# (4) Calcul du pourcentage de valeurs manquantes dans chaque combinaison des␣
 ↪deux variables qui en contiennent
print("Pourcentage de valeurs manquantes dans :")
print("    - le titre des références : " + str(round(214132 * 100 / (214132 +␣
 ↪136888 + 55548))) + "%")
print("    - le type des références : " + str(round(136888 * 100 / (214132 +␣
 ↪136888 + 55548))) + "%")
print("    - le titre et le type : " + str(round(55548 * 100 / (214132 +␣
 ↪136888 + 55548))) + "%")
```

```
Pourcentage de valeurs manquantes dans :
    - le titre des références : 53%
    - le type des références : 34%
    - le titre et le type : 14%
```

2.2 Corrélations entre les données manquantes

[11]:
```
# (1) Représentation de la proportion de données manquantes communes par␣
 ↪paire de variables
plt.rc('font', family = 'Times New Roman', size = 12)
msno.heatmap(biblio, figsize = (17.5/2.54, 9/2.54), fontsize = 12,␣
 ↪label_rotation = 0)
plt.show()
```

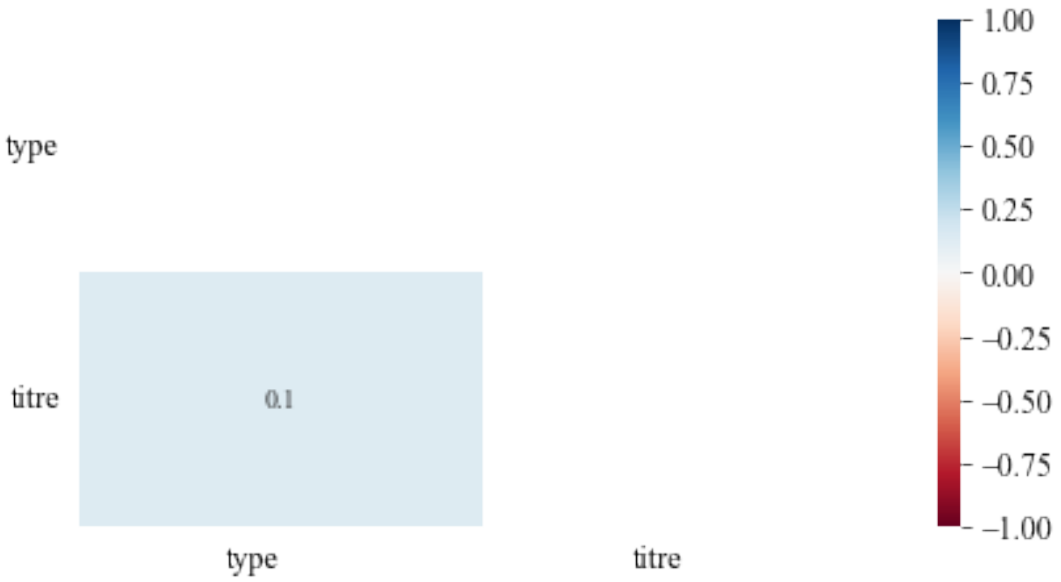

[12]:
```
# (2) Relation entre le type d'une référence et la probabilité que son titre␣
 ↪soit manquant
prop_nan_titre_par_type = []
for i in biblio["type"].unique():
    prop_nan_titre_par_type.append((biblio[biblio["type"] == i].isna().
 ↪mean()*100)["titre"])
list_type_ref = biblio["type"].unique()
```

```
list_type_ref[2] = "unknown"

plt.rc("font", family = "Times New Roman", size = 12)
fig, ax = plt.subplots(figsize = (17.5/2.54, 9/2.54))
ax.bar(x = list_type_ref, height = prop_nan_titre_par_type)
ax.spines[["right", "top"]].set_visible(False)
ax.set_title("Valeurs manquantes dans le titre des références")
ax.set_xlabel("Type de référence", labelpad = 8)
ax.tick_params(axis = "x", rotation = 90)
ax.set_ylabel("Pourcentage de valeurs manquantes", labelpad = 8)
ax.set_ylim(0,70)
plt.show()
```

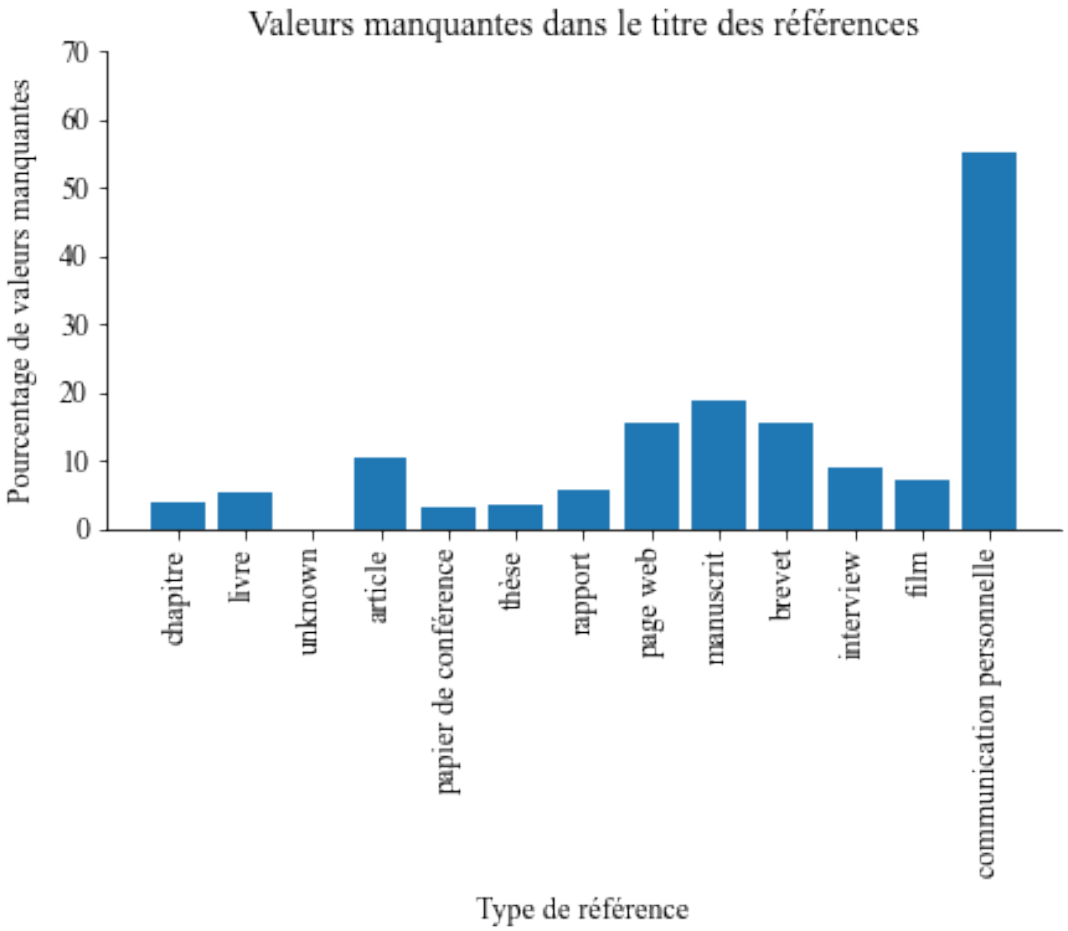

[13]:
```
# (3) Relation entre la discipline d'une thèse et la probabilité que le titre␣
↪des références citées soit manquant
prop_nan_titre_par_discipline = []
for i in biblio["discipline"].unique():
    prop_nan_titre_par_discipline.append((biblio[biblio["discipline"] == i].
↪isna().mean()*100)["titre"])

plt.rc("font", family = "Times New Roman", size = 12)
```

```
fig, ax = plt.subplots(figsize = (17.5/2.54, 9/2.54))
ax.bar(x = list(biblio["discipline"].unique()), height =␣
↪prop_nan_titre_par_discipline)
ax.spines[["right", "top"]].set_visible(False)
ax.set_title("Valeurs manquantes dans le titre des références")
ax.set_xlabel("Discipline", labelpad = 8)
ax.set_ylabel("Pourcentage de valeurs manquantes", labelpad = 8)
ax.set_ylim(0,40)
plt.show()
```

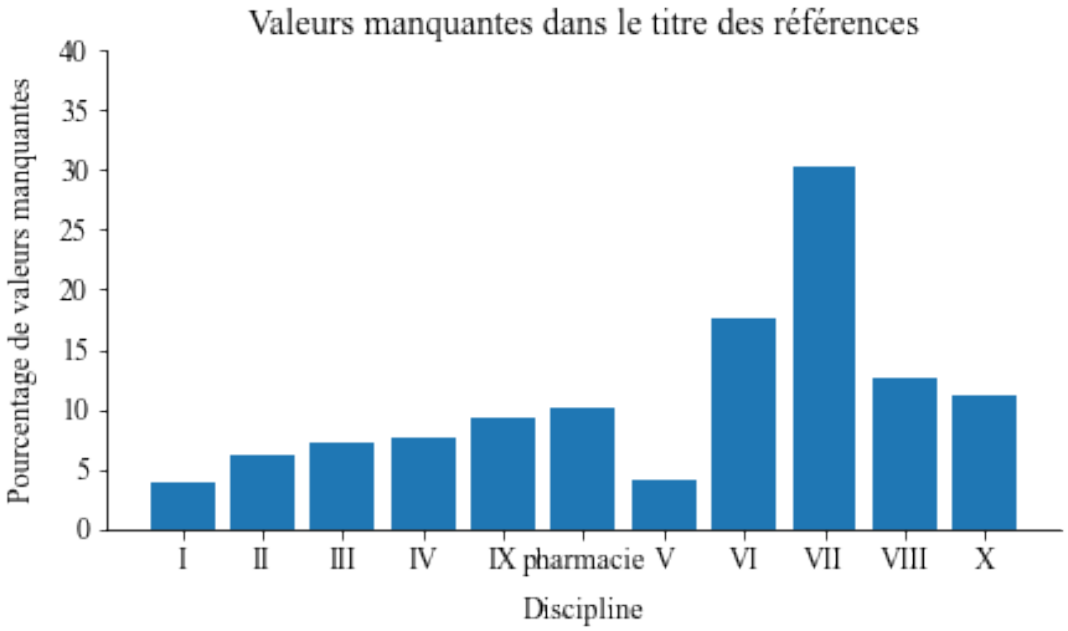

[14]:
```
# (4) Relation entre la discipline d'une thèse et la probabilité que le type␣
↪de référence cité soit manquant
prop_nan_type_par_discipline = []
for i in biblio["discipline"].unique():
    prop_nan_type_par_discipline.append((biblio[biblio["discipline"] == i].
↪isna().mean()*100)["type"])

plt.rc("font", family = "Times New Roman", size = 12)
fig, ax = plt.subplots(figsize = (17.5/2.54, 9/2.54))
ax.bar(x = list(biblio["discipline"].unique()), height =␣
↪prop_nan_type_par_discipline)
ax.spines[["right", "top"]].set_visible(False)
ax.set_title("Valeurs manquantes dans le type de référence")
ax.set_xlabel("Discipline", labelpad = 8)
ax.set_ylabel("Pourcentage de valeurs manquantes", labelpad = 8)
ax.set_ylim(0,40)
plt.show()
```

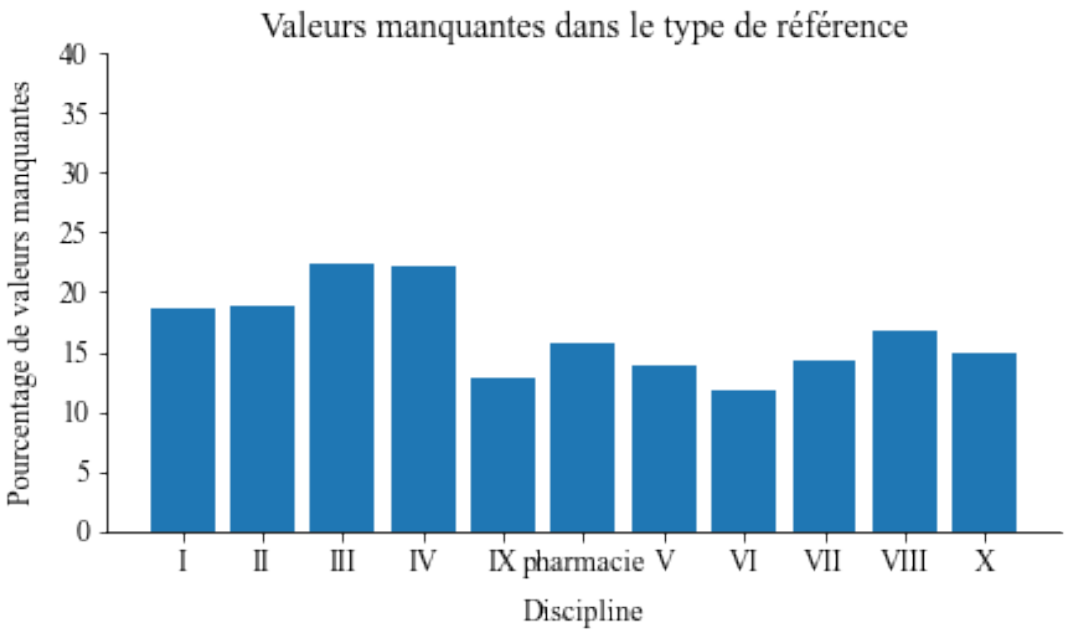

[15]:
```
# (5) Calcul du pourcentage de valeurs manquantes par thèse dans le titre et dans le type des références
prop_nan_titre_par_these = []
for i in biblio["numéro TEL"].unique():
    prop_nan_titre_par_these.append((biblio[biblio["numéro TEL"] == i].isna().mean()*100)["titre"])
prop_nan_type_par_these = []
for i in biblio["numéro TEL"].unique():
    prop_nan_type_par_these.append((biblio[biblio["numéro TEL"] == i].isna().mean()*100)["type"])
```

[16]:
```
# (6) Stockage des données de pourcentage de valeurs manquantes par thèse dans le titre et le type de référence dans un tableau à part
Tableau_nan_par_these = pd.DataFrame({"Valeurs_manquantes_dans_titre_ref" : prop_nan_titre_par_these, "Valeurs_manquantes_dans_type_ref" : prop_nan_type_par_these}, index = list(biblio["numéro TEL"].unique()))
```

[17]:
```
# (7) Copie du tableau dans le presse-papier pour le transférer dans Excel
Tableau_nan_par_these.to_clipboard(excel = True)
```

[18]:
```
# (8) Export du tableau en format csv
Tableau_nan_par_these.to_csv("table.exportcsv.csv")
```

[19]:
```
# (9) Relation entre une thèse et la probabilité que le titre des références citées dans cette thèse soit manquant
Tableau_nan_par_these = pd.read_csv(r"C:\Users\quent\Documents\DU Data Analyst 2022\UE n°4 - Rédaction d'un rapport d'analyse\Devoirs\table.exportcsv.csv", low_memory = False, encoding = "latin-1")
plt.rc("font", family = "Times New Roman", size = 12)
```

```
fig, ax = plt.subplots(figsize = (17.5/2.54, 9/2.54))
ax.hist(Tableau_nan_par_these["Valeurs_manquantes_dans_titre_ref"], bins = 10)
ax.spines[["right", "top"]].set_visible(False)
ax.set_xlabel("Pourcentage de valeurs manquantes dans le titre des␣
 ↪références", labelpad = 8)
ax.set_ylabel("Fréquence", labelpad = 8)
plt.show()
```

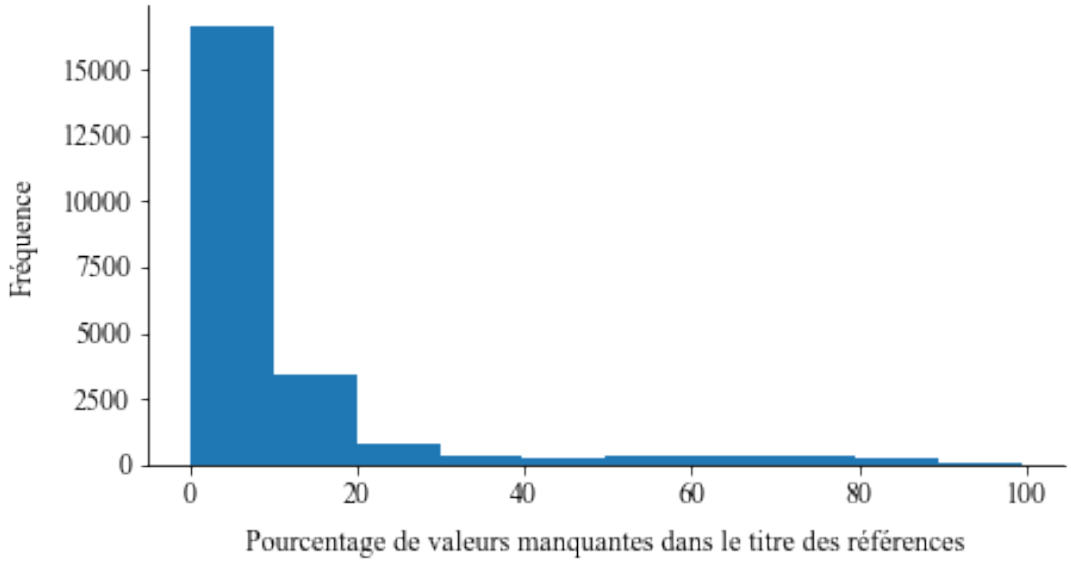

[20]:
```
# (10) Relation entre une thèse et la probabilité que le type de référence␣
 ↪cité dans cette thèse soit manquant
plt.rc("font", family = "Times New Roman", size = 12)
fig, ax = plt.subplots(figsize = (17.5/2.54, 9/2.54))
ax.hist(Tableau_nan_par_these["Valeurs_manquantes_dans_type_ref"], bins = 10)
ax.spines[["right", "top"]].set_visible(False)
ax.set_xlabel("Pourcentage de valeurs manquantes dans le type de référence",␣
 ↪labelpad = 8)
ax.set_ylabel("Fréquence", labelpad = 8)
plt.show()
```

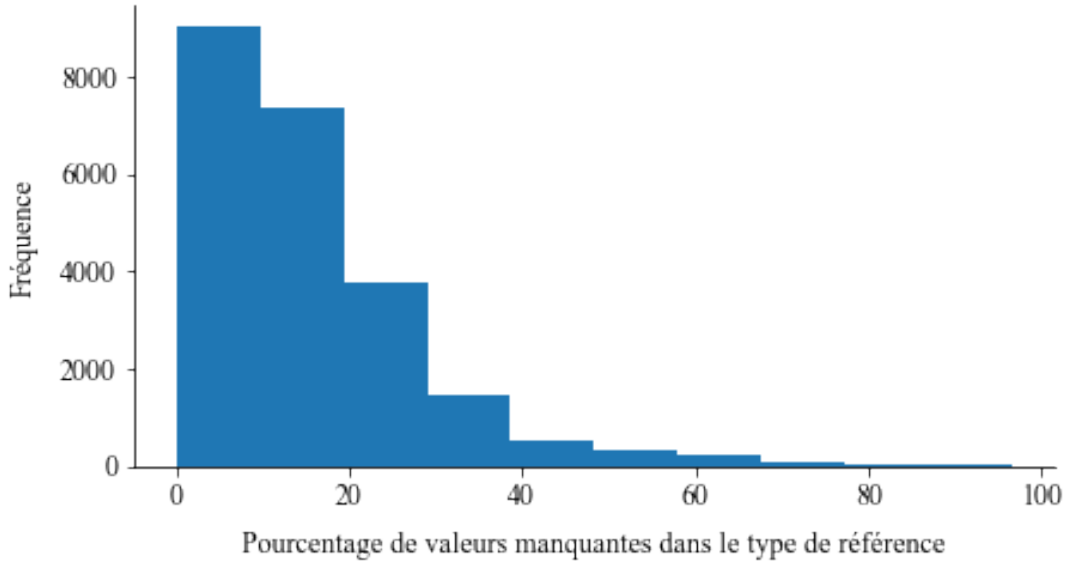

3 Nombre de références citées par thèse et discipline

[21]:
```
# (1) Calcul du nombre total de thèses présentes dans le jeu de données par␣
↪discipline
Nb_these_par_discipline = biblio.groupby(["discipline", "numéro TEL"]).size().
↪to_frame().reset_index().groupby("discipline").size()
print(Nb_these_par_discipline)
```

```
discipline
I              229
II            1359
III            654
IV            1003
IX            9430
V             2851
VI            2768
VII           1235
VIII          1551
X             1780
pharmacie       29
dtype: int64
```

[22]:
```
# (2) Retrait des thèses réalisées en pharmacie
biblio_sans_pharma = biblio[biblio["discipline"] != "pharmacie"]
```

[23]:
```
# (3) Calcul de la moyenne et de l'erreur standard du nombre de références␣
↪par thèse pour chaque discipline
Nb_ref_par_these_discipline = biblio_sans_pharma.pivot_table(values = "numéro␣
↪citation", index = "numéro TEL", columns = "discipline", aggfunc = "sum")
my_df1 = Nb_ref_par_these_discipline.copy(deep = True)
my_df2 = pd.DataFrame()
```

```
my_df2.index = ["Moyenne", "ESM"]
for i in my_df1.columns:
    my_df2[i] = [my_df1[i].values[~np.isnan(my_df1[i].values)].mean(),␣
 ↪my_df1[i].values[~np.isnan(my_df1[i].values)].std() / np.sqrt(len(my_df1[i].
 ↪values[~np.isnan(my_df1[i].values)]))]
Moyenne_ESM_nb_ref_par_these_discipline = my_df2.copy(deep = True)
Moyenne_ESM_nb_ref_par_these_discipline
```

[23]:

```
                  I          II         III          IV         IX          V␣
 ↪ \
Moyenne  105.170306  108.726269  105.068807  104.039880  74.667232  67.926692
ESM        4.800131    1.690197    2.332825    2.149698   0.523056   0.851124

                VI         VII        VIII           X
Moyenne  75.084899   68.682591   81.056738   88.670225
ESM       0.945796    1.847050    1.566584    1.626058
```

[24]:

```
# (4) Représentation en barplot
plt.rc("font", family = "Times New Roman", size = 12)
fig, ax = plt.subplots(figsize = (17.5/2.54, 9/2.54))
ax.bar(x = Moyenne_ESM_nb_ref_par_these_discipline.
 ↪columns[[0,1,2,3,5,6,7,8,4,9]], height =␣
 ↪Moyenne_ESM_nb_ref_par_these_discipline.loc["Moyenne"].
 ↪values[[0,1,2,3,5,6,7,8,4,9]])
ax.errorbar(x = Moyenne_ESM_nb_ref_par_these_discipline.
 ↪columns[[0,1,2,3,5,6,7,8,4,9]], y = Moyenne_ESM_nb_ref_par_these_discipline.
 ↪loc["Moyenne"].values[[0,1,2,3,5,6,7,8,4,9]], yerr =␣
 ↪Moyenne_ESM_nb_ref_par_these_discipline.loc["ESM"].
 ↪values[[0,1,2,3,5,6,7,8,4,9]], fmt='_', capsize = 4, capthick = 1.5, ecolor␣
 ↪= "black")
ax.spines[["right", "top"]].set_visible(False)
ax.set_xlabel("Disciplines", labelpad = 8)
ax.set_ylabel("Nombre de références par thèse", labelpad = 8)
ax.set_ylim(0,140)
plt.show()
```

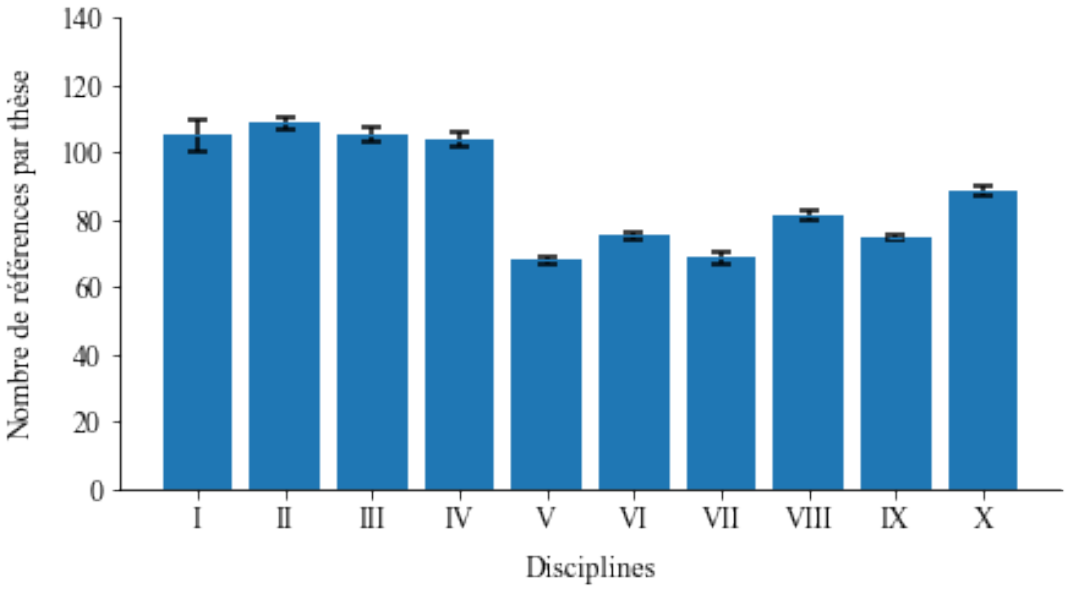

[25]:
```
# (5) Test de la normalité des données pour chaque discipline (représentation
 ↪des distributions en affichant le résultat des tests dans le titre des
 ↪graphiques)
Nb_ref_avec_discipline = Nb_ref_par_these_discipline.stack().reset_index()
Nb_ref_avec_discipline = Nb_ref_avec_discipline.rename(columns = {"numéro
 ↪TEL": "these"})
Nb_ref_avec_discipline["nb_ref"] =
 ↪Nb_ref_avec_discipline[Nb_ref_avec_discipline.columns[2]]
Nb_ref_avec_discipline = Nb_ref_avec_discipline.drop(columns =
 ↪[Nb_ref_avec_discipline.columns[2]])

plt.rc("font", family = "Times New Roman", size = 12)
fig, ax = plt.subplots(nrows = 3, ncols = 4, figsize = (35/2.54, 20/2.54))
row = 0
col = 0
for i in Nb_ref_avec_discipline["discipline"].unique():
    test_shapiro = stats.
 ↪shapiro(Nb_ref_avec_discipline[Nb_ref_avec_discipline["discipline"] ==
 ↪i]["nb_ref"])
    ax[row,col].
 ↪hist(Nb_ref_avec_discipline[Nb_ref_avec_discipline["discipline"] ==
 ↪i]["nb_ref"], bins = 10)
    if test_shapiro[1] < 0.001:
        ax[row,col].set_title(i + " ; " + "W = " + str(round(test_shapiro[0],
 ↪2)) + " ; P < " + str(0.001))
    else:
        ax[row,col].set_title(i + " ; " + "W = " + str(round(test_shapiro[0],
 ↪2)) + " ; P = " + str(round(test_shapiro[1], 3)))
    ax[row,col].spines[["right", "top"]].set_visible(False)
    ax[row,col].set_xlabel("Nombre de références par thèse", labelpad = 8)
```

```
    ax[row,col].set_ylabel("Fréquence", labelpad = 8)
    col = col + 1
    if col % 4 == 0:
        row = row + 1
        col = 0
fig.delaxes(ax[2][3])
fig.delaxes(ax[2][2])
for ax in ax.flat:
    ax.label_outer()
plt.subplots_adjust(wspace = 0.20, hspace = 0.32)
plt.show()
```

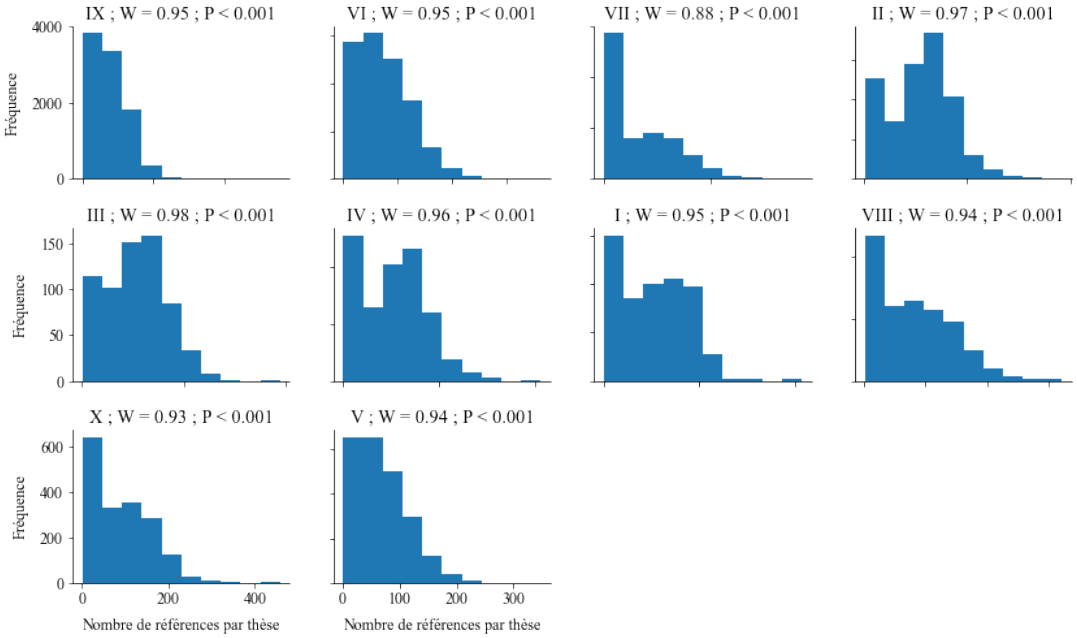

[26]:
```
# (6) Kruskal-Wallis sur le nombre de références par thèse en fonction de la␣
↪discipline
my_dict = {}
for i in list(Moyenne_ESM_nb_ref_par_these_discipline.
↪columns[[0,1,2,3,5,6,7,8,4,9]]):
    my_dict[i] = Nb_ref_avec_discipline[Nb_ref_avec_discipline["discipline"]␣
↪== i]["nb_ref"]
stats.kruskal(my_dict["I"], my_dict["II"], my_dict["III"], my_dict["IV"],␣
↪my_dict["V"], my_dict["VI"], my_dict["VII"], my_dict["VIII"],␣
↪my_dict["IX"], my_dict["X"])
```

[26]:
```
KruskalResult(statistic=850.2820953446758, pvalue=3.1724295932050167e-177)
```

[27]:
```
# (7) Tests post-hoc ; rq : le seuil de significativité est abaissé à 0.05 /␣
↪55 = 9.09e-4 (55 étant le nombre de comparaisons deux-à-deux effectuées)
```

```
post_hoc_result = sp.posthoc_dunn([my_dict["I"], my_dict["II"],␣
↪my_dict["III"], my_dict["IV"], my_dict["V"], my_dict["VI"], my_dict["VII"],␣
↪my_dict["VIII"], my_dict["IX"], my_dict["X"]])
post_hoc_result
```

[27]:

	1	2	3	4	5
1	1.000000e+00	4.388670e-02	2.030350e-01	7.502829e-01	5.540655e-14
2	4.388670e-02	1.000000e+00	3.315939e-01	3.754412e-03	2.844549e-89
3	2.030350e-01	3.315939e-01	1.000000e+00	1.386127e-01	1.508697e-45
4	7.502829e-01	3.754412e-03	1.386127e-01	1.000000e+00	6.319132e-49
5	5.540655e-14	2.844549e-89	1.508697e-45	6.319132e-49	1.000000e+00
6	8.114970e-09	7.591888e-60	6.088617e-30	4.671974e-30	6.979874e-06
7	1.000366e-17	1.931697e-83	2.067043e-49	2.914581e-51	3.184638e-03
8	8.688445e-07	4.720200e-40	1.115405e-21	4.732379e-20	9.836198e-08
9	1.137477e-09	1.847870e-80	8.705812e-36	1.986936e-38	3.243062e-07
10	3.086026e-04	2.812836e-28	1.628547e-14	2.454781e-12	3.043110e-18

	6	7	8	9	10
1	8.114970e-09	1.000366e-17	8.688445e-07	1.137477e-09	3.086026e-04
2	7.591888e-60	1.931697e-83	4.720200e-40	1.847870e-80	2.812836e-28
3	6.088617e-30	2.067043e-49	1.115405e-21	8.705812e-36	1.628547e-14
4	4.671974e-30	2.914581e-51	4.732379e-20	1.986936e-38	2.454781e-12
5	6.979874e-06	3.184638e-03	9.836198e-08	3.243062e-07	3.043110e-18
6	1.000000e+00	1.189887e-10	1.283139e-01	6.194251e-01	2.442870e-06
7	1.189887e-10	1.000000e+00	1.870790e-12	4.260971e-12	9.463901e-23
8	1.283139e-01	1.870790e-12	1.000000e+00	3.137842e-02	6.266030e-03
9	6.194251e-01	4.260971e-12	3.137842e-02	1.000000e+00	2.582618e-09
10	2.442870e-06	9.463901e-23	6.266030e-03	2.582618e-09	1.000000e+00

[28]:
```
# (8) Focus sur les thèses citant peu de références : affichage du nombre et␣
↪du pourcentage de thèses citant moins de 20 références
Nb_ref_par_these_discipline["somme"] = Nb_ref_par_these_discipline.sum(axis =␣
↪1, numeric_only = True)
print("Nombre de thèses citant moins de 20 références : " +␣
↪str(Nb_ref_par_these_discipline[Nb_ref_par_these_discipline["somme"] < 20].
↪shape[0]))
print("Pourcentage : " +␣
↪str(round(Nb_ref_par_these_discipline[Nb_ref_par_these_discipline["somme"]␣
↪< 20].shape[0] * 100 / Nb_ref_par_these_discipline.shape[0], 2)) + "%")
```

```
Nombre de thèses citant moins de 20 références : 3955
Pourcentage : 17.3%
```

[29]:
```
# (9) Représentation de la distribution du nombre de références par thèse,␣
↪toute discipline confondue
plt.rc("font", family = "Times New Roman", size = 12)
fig, ax = plt.subplots(figsize = (17.5/2.54, 9/2.54))
ax.hist(Nb_ref_par_these_discipline["somme"], bins = 21)
ax.spines[["right", "top"]].set_visible(False)
ax.set_xlabel("Nombre de références par thèse", labelpad = 8)
ax.set_ylabel("Fréquence", labelpad = 8)
```

```
plt.show()
```

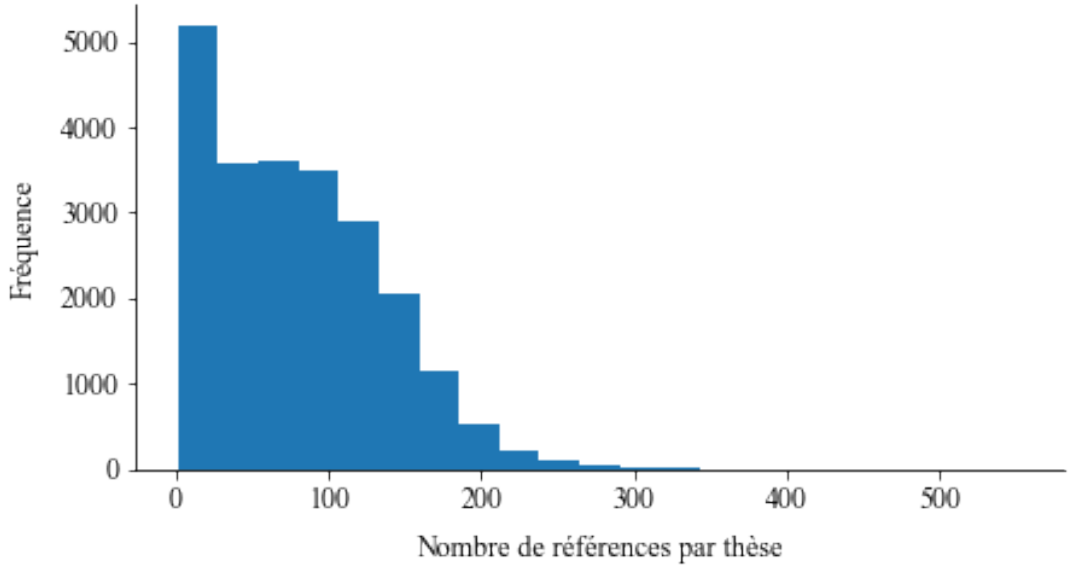

4 Type de référence citée par thèse et discipline

[30]:
```
# (1) Retrait des références dont le type est inconnu
biblio_sans_pharma_ni_nan = biblio_sans_pharma[biblio_sans_pharma["type"].
 ↪notnull()]
```

[31]:
```
# (2) Calcul des proportions de chaque type de références citées par thèse,␣
 ↪pour chaque discipline (création d'un tableau par discipline, regroupés␣
 ↪ensuite dans un même dictionnaire)
my_dict = {}
for discipline in biblio_sans_pharma_ni_nan["discipline"].unique():
    my_df_number =␣
 ↪biblio_sans_pharma_ni_nan[biblio_sans_pharma_ni_nan["discipline"] ==␣
 ↪discipline].pivot_table(values = "numéro citation", index = "numéro TEL",␣
 ↪columns = "type", aggfunc = "sum")
    my_df_prop = pd.DataFrame(index = my_df_number.index, columns =␣
 ↪biblio_sans_pharma_ni_nan["type"].unique())
    my_df_prop = my_df_prop.fillna(0)
    for i in my_df_number.index:
        for j in my_df_number.columns:
            my_df_prop.loc[i,j] = my_df_number.loc[i,j]*100 / my_df_number.
 ↪loc[i,:].sum()
    my_df_prop = my_df_prop.fillna(0)
    my_dict[discipline] = my_df_prop.copy(deep = True)
print("Proportion de chaque type de référence dans les thèses de la␣
 ↪discipline I :")
print("")
print(my_dict["I"].head())
```

```
Proportion de chaque type de référence dans les thèses de la discipline I :

                    chapitre      livre    article  papier de conférence  \
numéro TEL
halshs-00005971v1   24.615385  16.153846  56.923077              2.307692
tel-00125323v1      13.215859  37.004405  49.779736              0.000000
tel-00150545v1       3.571429  69.642857  26.785714              0.000000
tel-00168467v1     100.000000   0.000000   0.000000              0.000000
tel-00184150v1      14.634146  36.585366  48.780488              0.000000

                   thèse  rapport  page web  manuscrit  brevet  interview  \
numéro TEL
halshs-00005971v1    0.0      0.0       0.0          0       0          0
tel-00125323v1       0.0      0.0       0.0          0       0          0
tel-00150545v1       0.0      0.0       0.0          0       0          0
tel-00168467v1       0.0      0.0       0.0          0       0          0
tel-00184150v1       0.0      0.0       0.0          0       0          0

                   film  communication personnelle
numéro TEL
halshs-00005971v1     0                         0
tel-00125323v1        0                         0
tel-00150545v1        0                         0
tel-00168467v1        0                         0
tel-00184150v1        0                         0
```

[32]:
```
# (3) Calcul de la moyenne et de l'erreur standard de la proportion de chaque␣
↪type de références citées par thèse, pour chaque discipline
Moyenne_Prop_type_ref_par_these = pd.DataFrame(index = my_dict.keys(),␣
↪columns = biblio_sans_pharma_ni_nan["type"].unique())
ESM_Prop_type_ref_par_these = pd.DataFrame(index = my_dict.keys(), columns =␣
↪biblio_sans_pharma_ni_nan["type"].unique())
for discipline in my_dict.keys():
    for i in my_dict[discipline].columns:
        Moyenne_Prop_type_ref_par_these.loc[discipline, i] =␣
↪my_dict[discipline][i].values[~np.isnan(my_dict[discipline][i].values)].
↪mean()
        ESM_Prop_type_ref_par_these.loc[discipline, i] =␣
↪my_dict[discipline][i].values[~np.isnan(my_dict[discipline][i].values)].
↪std() / np.sqrt(len(my_dict[discipline][i].values[~np.
↪isnan(my_dict[discipline][i].values)]))
```

[33]:
```
# (4) Représentation de la proportion moyenne de chaque type de références␣
↪citées par thèse, en fonction de la discipline
# ___(4a) Regroupement des types autres que chapitre, livre et article dans␣
↪une catégorie autre
Moyenne_Prop_type_ref_par_these_4_cat = Moyenne_Prop_type_ref_par_these.
↪copy(deep = True)
Autre = []
for i in range(0,len(list(Moyenne_Prop_type_ref_par_these.index))):
```

```
    Autre.append(np.array(Moyenne_Prop_type_ref_par_these_4_cat.iloc[i,3:]).
 ↪sum())
Moyenne_Prop_type_ref_par_these_4_cat["autre"] = Autre
Moyenne_Prop_type_ref_par_these_4_cat = Moyenne_Prop_type_ref_par_these_4_cat.
 ↪drop(columns = list(Moyenne_Prop_type_ref_par_these.columns)[3:])

# ___(4b) Représentation en stacked bar chart
List_types = list(Moyenne_Prop_type_ref_par_these_4_cat.columns)
k = np.array(list(Moyenne_Prop_type_ref_par_these_4_cat["chapitre"].
 ↪values[[0,1,2,3,5,6,7,8,4,9]]))

plt.rc("font", family = "Times New Roman", size = 12)
fig, ax = plt.subplots(figsize = (17.5/2.54, 9/2.54))
plt.gca().spines["right"].set_visible(False)
plt.gca().spines["top"].set_visible(False)
ax.set_xlabel("Discipline", labelpad = 8)
ax.set_ylabel("Pourcentage moyen de références par thèse", labelpad = 8)
ax.set_ylim(0,100)
ax.bar(list(Moyenne_Prop_type_ref_par_these_4_cat["chapitre"].
 ↪index[[0,1,2,3,5,6,7,8,4,9]]),␣
 ↪list(Moyenne_Prop_type_ref_par_these_4_cat["chapitre"].
 ↪values[[0,1,2,3,5,6,7,8,4,9]]), label = "chapitre", width = 0.75, alpha = 0.
 ↪5)
for i in List_types[1:]:
    ax.bar(list(Moyenne_Prop_type_ref_par_these_4_cat[i].
 ↪index[[0,1,2,3,5,6,7,8,4,9]]),␣
 ↪list(Moyenne_Prop_type_ref_par_these_4_cat[i].
 ↪values[[0,1,2,3,5,6,7,8,4,9]]), bottom = k, label = i, width = 0.75, alpha␣
 ↪= 0.5)
    k = k + np.array(list(Moyenne_Prop_type_ref_par_these_4_cat[i].
 ↪values[[0,1,2,3,5,6,7,8,4,9]]))
ax.legend(bbox_to_anchor = (0.065, 1.03), frameon = False, ncol = 4)
plt.show()
```

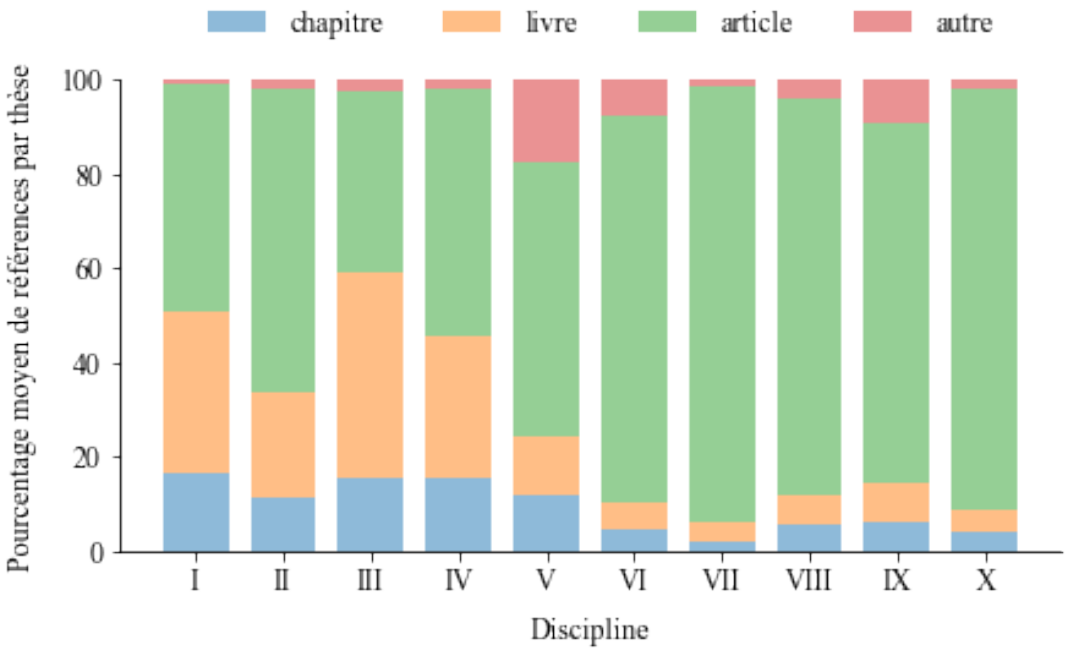

[34]:
```
# (5) Représentation de la proportion d'articles scientifiques cités par␣
 ↪thèse, en fonction de la discipline
plt.rc("font", family = "Times New Roman", size = 12)
fig, ax = plt.subplots(figsize = (17.5/2.54, 9/2.54))
ax.bar(x = list(Moyenne_Prop_type_ref_par_these.
 ↪index[[0,1,2,3,5,6,7,8,4,9]]), height =␣
 ↪list(Moyenne_Prop_type_ref_par_these["article"][[0,1,2,3,5,6,7,8,4,9]]))
ax.errorbar(x = list(Moyenne_Prop_type_ref_par_these.
 ↪index[[0,1,2,3,5,6,7,8,4,9]]), y =␣
 ↪list(Moyenne_Prop_type_ref_par_these["article"][[0,1,2,3,5,6,7,8,4,9]]),␣
 ↪yerr = list(ESM_Prop_type_ref_par_these["article"][[0,1,2,3,5,6,7,8,4,9]]),␣
 ↪fmt='_', capsize = 4, capthick = 1.5, ecolor = "black")
ax.spines[["right", "top"]].set_visible(False)
ax.set_xlabel("Discipline", labelpad = 8)
ax.set_ylabel("Pourcentage d'articles cités par thèse", labelpad = 8)
ax.set_ylim(0,100)
plt.show()
```

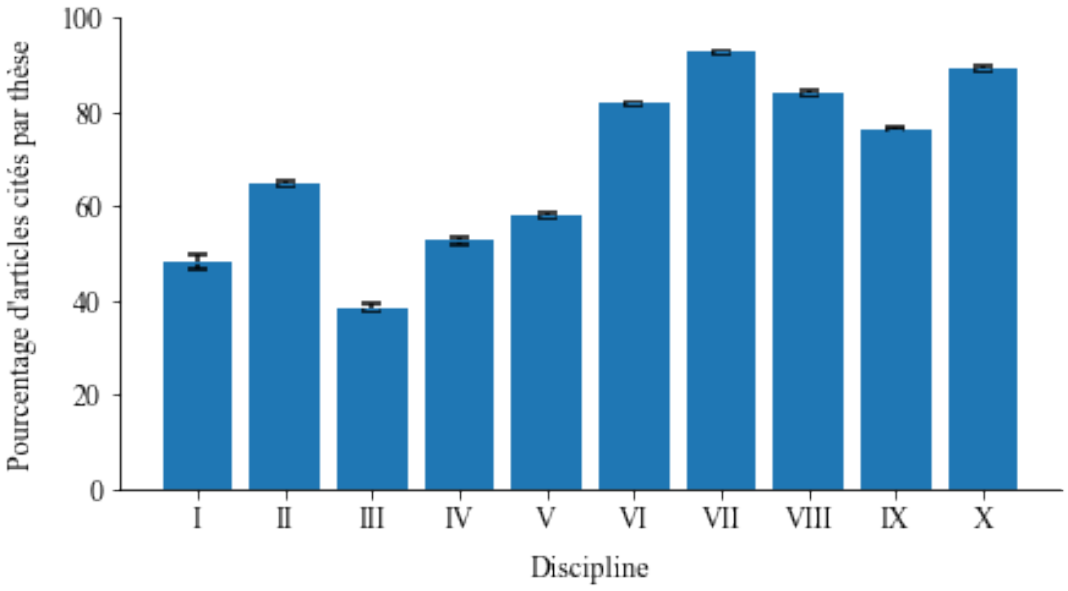

[35]:
```
# (6) Test de la normalité des données pour chaque discipline (représentation
 ↪des distributions en affichant le résultat des tests dans le titre des
 ↪graphiques)
plt.rc("font", family = "Times New Roman", size = 12)
fig, ax = plt.subplots(nrows = 3, ncols = 4, figsize = (35/2.54, 20/2.54))
list_articles = []
for i in my_dict.keys():
    list_articles.append(list(my_dict[i]["article"]))

row = 0
col = 0
for i in range(0, len(list_articles)):
    test_shapiro = stats.shapiro(list_articles[i])
    ax[row,col].hist(list_articles[i], bins = 10)
    if test_shapiro[1] < 0.001:
        ax[row,col].set_title(list(my_dict.keys())[i] + " ; " + "W = " +
 ↪str(round(test_shapiro[0], 2)) + " ; P < " + str(0.001))
    else:
        ax[row,col].set_title(list(my_dict.keys())[i] + " ; " + "W = " +
 ↪str(round(test_shapiro[0], 2)) + " ; P = " + str(round(test_shapiro[1], 3)))
    ax[row,col].spines[["right", "top"]].set_visible(False)
    ax[row,col].set_xlabel("Pourcentage d'articles cités par thèse", labelpad
 ↪= 8)
    ax[row,col].set_ylabel("Fréquence", labelpad = 8)
    col = col + 1
    if col % 4 == 0:
        row = row + 1
        col = 0
fig.delaxes(ax[2][2])
fig.delaxes(ax[2][3])
```

```
for ax in ax.flat:
    ax.label_outer()
plt.subplots_adjust(wspace = 0.20, hspace = 0.32)
plt.show()
```

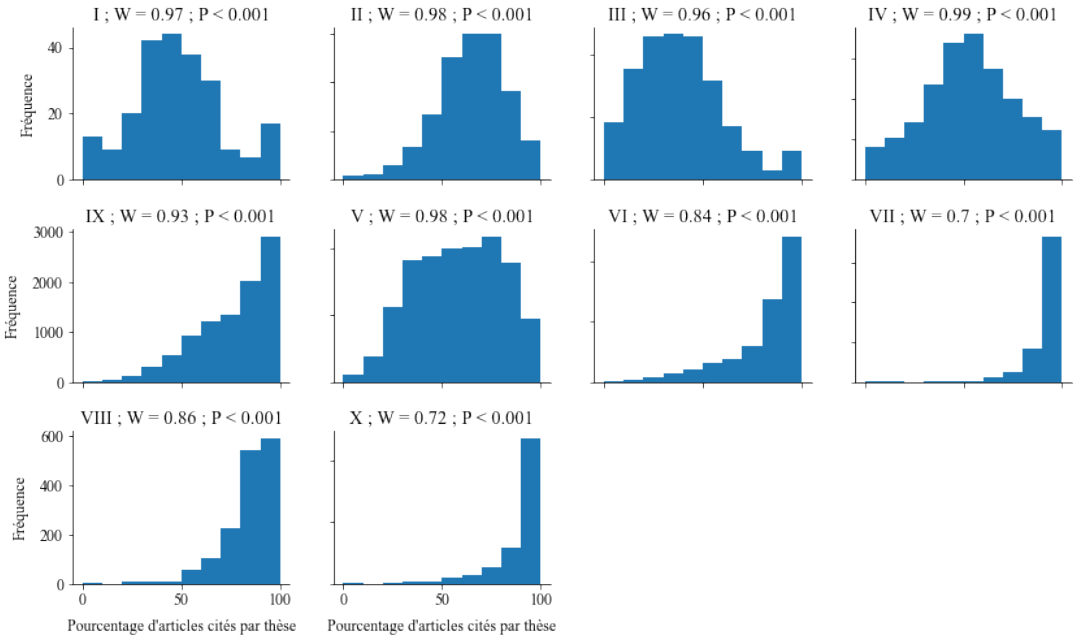

[36]:
```
# (7) Kruskal-Wallis sur le pourcentage d'articles cités par thèse en␣
↪fonction de la discipline
stats.kruskal(list_articles[0], list_articles[1], list_articles[2],␣
↪list_articles[3], list_articles[4], list_articles[5], list_articles[6],␣
↪list_articles[7], list_articles[8], list_articles[9])
```

[36]:
```
KruskalResult(statistic=6605.611024663464, pvalue=0.0)
```

[37]:
```
# (8) Tests post-hoc (le seuil de significativité est abaissé à 0.05 / 55 = 9.
↪09e-4)
post_hoc_result = sp.posthoc_dunn([list_articles[0], list_articles[1],␣
↪list_articles[2], list_articles[3], list_articles[4], list_articles[5],␣
↪list_articles[6], list_articles[7], list_articles[8], list_articles[9]])
post_hoc_result
```

[37]:

	1	2	3	4	5
1	1.000000e+00	6.216771e-10	3.574583e-04	1.137579e-01	7.531515e-54
2	6.216771e-10	1.000000e+00	3.855658e-51	4.851459e-15	2.240196e-92
3	3.574583e-04	3.855658e-51	1.000000e+00	8.620754e-15	2.482583e-229
4	1.137579e-01	4.851459e-15	8.620754e-15	1.000000e+00	5.677217e-168
5	7.531515e-54	2.240196e-92	2.482583e-229	5.677217e-168	1.000000e+00
6	1.279968e-04	5.902426e-08	2.973113e-35	6.044975e-05	2.204597e-284
7	2.193101e-81	9.242955e-153	4.808535e-292	8.694933e-232	1.635038e-38

8	2.108967e-160	0.000000e+00	0.000000e+00	0.000000e+00	5.906274e-198
9	5.457302e-83	1.234369e-136	3.762233e-271	4.103269e-209	5.677724e-34
10	2.469663e-136	1.877489e-286	0.000000e+00	0.000000e+00	8.032425e-167

	6	7	8	9	10
1	1.279968e-04	2.193101e-81	2.108967e-160	5.457302e-83	2.469663e-136
2	5.902426e-08	9.242955e-153	0.000000e+00	1.234369e-136	1.877489e-286
3	2.973113e-35	4.808535e-292	0.000000e+00	3.762233e-271	0.000000e+00
4	6.044975e-05	8.694933e-232	0.000000e+00	4.103269e-209	0.000000e+00
5	2.204597e-284	1.635038e-38	5.906274e-198	5.677724e-34	8.032425e-167
6	1.000000e+00	0.000000e+00	0.000000e+00	8.067277e-268	0.000000e+00
7	0.000000e+00	1.000000e+00	3.523855e-75	9.857099e-02	1.195265e-45
8	0.000000e+00	3.523855e-75	1.000000e+00	1.941731e-51	1.048360e-07
9	8.067277e-268	9.857099e-02	1.941731e-51	1.000000e+00	1.208050e-27
10	0.000000e+00	1.195265e-45	1.048360e-07	1.208050e-27	1.000000e+00

5 Nombre de références citées par thèse et type de référence

5.1 Thèses de SHS

[38]:
```
# (1) Création d'un tableau avec une colonne "thèse", une colonne␣
↪"discipline", une colonne "type de références", une colonne "pourcentage de␣
↪références citées" et une colonne "nombre de thèses"
Nb_ref_par_these_discipline_sans_nan = biblio_sans_pharma_ni_nan.
↪pivot_table(values = "numéro citation", index = "numéro TEL", columns =␣
↪"discipline", aggfunc = "sum").fillna(0)
theses = list(Nb_ref_par_these_discipline_sans_nan.index)
nb_ref = [Nb_ref_par_these_discipline_sans_nan.loc[i,:].max() for i in␣
↪Nb_ref_par_these_discipline_sans_nan.index]
Nb_ref_par_these = pd.DataFrame({"these": theses, "nb_ref": nb_ref})

df_final = pd.DataFrame(columns = ["these", "discipline", "type_ref",␣
↪"prop_type_ref"])
for i in my_dict.keys():
    my_df = my_dict[i].copy(deep = True)
    my_df = my_df.stack().reset_index()
    my_df["these"] = my_df["numéro TEL"]
    my_df["discipline"] = [i] * my_df.shape[0]
    my_df["type_ref"] = my_df["level_1"]
    my_df["prop_type_ref"] = my_df[my_df.columns[2]]
    my_df = my_df.drop(columns = ["numéro TEL", "level_1", my_df.columns[2]])
    df_final = pd.merge(df_final, my_df, how = "outer")
df_final = pd.merge(df_final, Nb_ref_par_these, how = "left", on = "these")
df_final.head()
```

[38]:

	these	discipline	type_ref	prop_type_ref	nb_ref
0	halshs-00005971v1	I	chapitre	24.615385	130.0
1	halshs-00005971v1	I	livre	16.153846	130.0
2	halshs-00005971v1	I	article	56.923077	130.0
3	halshs-00005971v1	I	papier de conférence	2.307692	130.0

```
4  halshs-00005971v1          I                  thèse       0.000000   130.0
```

[39]:
```
# (2) Représentation de la proportion de livres et chapitres de livres cités␣
 ↪par thèse en SHS en fonction du nombre de références citées par thèse
# ___(2a) Sélection des thèses de SHS
SHS = ["I", "II", "III", "IV"]
df_SHS = pd.DataFrame(columns = list(df_final.columns))
for i in SHS:
    my_df = df_final[df_final["discipline"] == i]
    df_SHS = pd.merge(df_SHS, my_df, how = "outer")
prop_livres_chapitres = list(df_SHS[df_SHS["type_ref"] ==␣
 ↪"livre"]["prop_type_ref"].values + df_SHS[df_SHS["type_ref"] ==␣
 ↪"chapitre"]["prop_type_ref"].values)
nb_ref = list(df_SHS[df_SHS["type_ref"] == "livre"]["nb_ref"].values)
discipline = ["SHS"] * len(nb_ref)
df_SHS = pd.DataFrame({"prop_livres_chapitres": prop_livres_chapitres,␣
 ↪"nb_ref": nb_ref, "discipline": discipline})

# ___(2b) Représentation en scatter plot, la ligne rouge représentant la␣
 ↪droite de régression
model_SHS = ols("prop_livres_chapitres ~ nb_ref", data = df_SHS).fit()
coeffs_SHS = model_SHS.params
ic_SHS, slope_SHS = coeffs_SHS
fig, ax = plt.subplots(figsize = (17.5/2.54, 9/2.54))
sns.scatterplot(x = "nb_ref", y = "prop_livres_chapitres", data = df_SHS,␣
 ↪alpha = 0.2, color = "black", s = 25)
ax.axline(xy1 = (0, ic_SHS), slope = slope_SHS, color = "red")
ax.set_ylim(0, 100)
ax.set_xlabel("Nombre de références par thèse", labelpad = 8)
ax.set_ylabel("Pourcentage de livres et chapitres de livres", labelpad = 8)
ax.spines[["top", "right"]].set_visible(False)
plt.show()
```

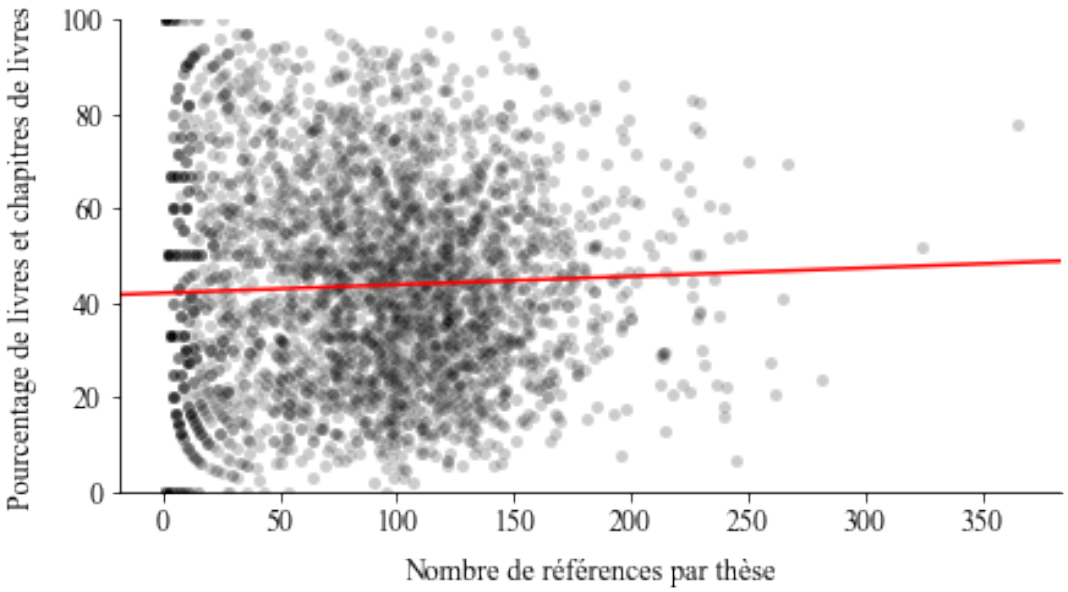

[40]:
```
# (3) Affichage de l'équation de la droite de régression :
print("y = " + str(ic_SHS) + " + " + str(slope_SHS) + "x")
```

```
y = 42.059626652741066 + 0.017718721528044858x
```

[41]:
```
# (4) Test de la normalité de la distribution des données des deux variables␣
↪analysées
test_shapiro_1 = stats.shapiro(df_SHS["prop_livres_chapitres"])
test_shapiro_2 = stats.shapiro(df_SHS["nb_ref"])
plt.rc("font", family = "Times New Roman", size = 12)
fig, ax = plt.subplots(nrows = 1, ncols = 2, figsize = (24/2.54, 9/2.54))
ax[0].hist(df_SHS["prop_livres_chapitres"], bins = 10)
ax[0].spines[["right", "top"]].set_visible(False)
ax[0].set_title("W = " + str(round(test_shapiro_1[0], 2)) + " ; P = " +␣
↪str(round(test_shapiro_1[1], 2)))
ax[0].set_xlabel("Pourcentage de livres et chapitres cités par thèse",␣
↪labelpad = 8)
ax[0].set_ylabel("Fréquence", labelpad = 8)
ax[1].hist(df_SHS["nb_ref"], bins = 10)
ax[1].spines[["right", "top"]].set_visible(False)
ax[1].set_title("W = " + str(round(test_shapiro_2[0], 2)) + " ; P = " +␣
↪str(round(test_shapiro_2[1], 2)))
ax[1].set_xlabel("Nombre de références par thèse", labelpad = 8)
ax[1].set_ylabel("Fréquence", labelpad = 8)
plt.subplots_adjust(wspace = 0.30)
plt.show()
```

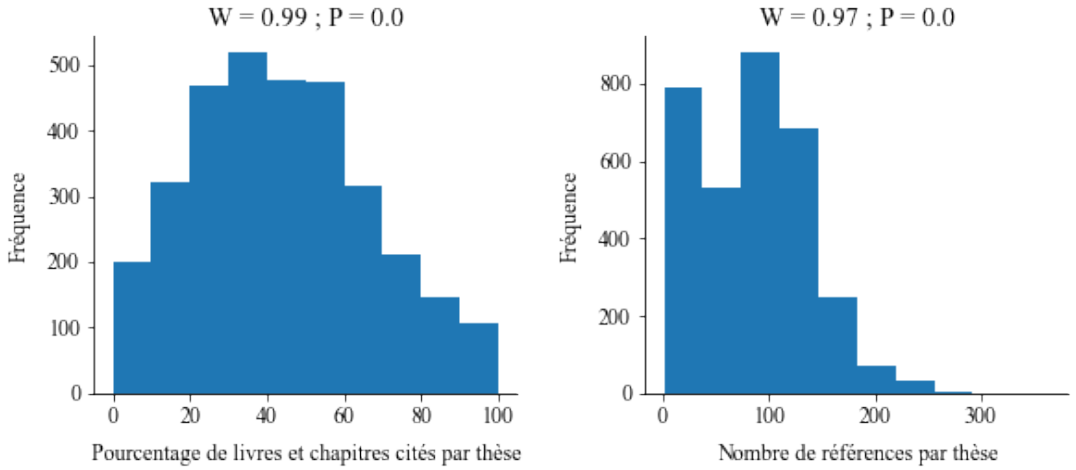

[42]:
```
# (5) Affichage des paramètres du modèle
print(model_SHS.summary())
```

```
                            OLS Regression Results
==============================================================================
```

```
=
Dep. Variable:     prop_livres_chapitres   R-squared:
0.002
Model:                               OLS   Adj. R-squared:
0.001
Method:                    Least Squares   F-statistic:
5.329
Date:                   Sat, 10 Sep 2022   Prob (F-statistic):
0.0210
Time:                           11:07:02   Log-Likelihood:
-14815.
No. Observations:                   3245   AIC:
2.963e+04
Df Residuals:                       3243   BIC:
2.965e+04
Df Model:                              1
Covariance Type:               nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept     42.0596      0.766     54.891      0.000      40.557      43.562
nb_ref         0.0177      0.008      2.308      0.021       0.003       0.033
==============================================================================
Omnibus:                      104.517   Durbin-Watson:                   1.619
Prob(Omnibus):                  0.000   Jarque-Bera (JB):               84.084
Skew:                           0.315   Prob(JB):                     5.51e-19
Kurtosis:                       2.525   Cond. No.                         187.
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly
specified.
```

[43]:
```python
# (6) Calcul de l'erreur standard résiduelle
# ___(6a) Création d'une fonction dédiée à ce calcul
def erreur_standard_residuelle(my_model, nb_ind):
    """Calcule l'erreur standard résiduelle (ESR) d'un modèle de régression␣
 ↪linéaire.

    Parameters
    ----------
    arg_1 : statsmodels.regression.linear_model.RegressionResultsWrapper
        Le modèle à partir duquel calculer l'ESR.
    arg_2 : int
        La taille de l'échantillon.

    Returns
    ----------
    float
    """
    residuals_sq = my_model.resid ** 2
```

```
    resid_sum_of_sq = sum(residuals_sq)
    deg_freedom = nb_ind - 2
    res = np.sqrt(resid_sum_of_sq/deg_freedom)
    return res

# ___(6b) Affichage du résultat
print("ESR = " + str(erreur_standard_residuelle(model_SHS,␣
↪len(df_SHS["prop_livres_chapitres"].index))))
```

```
ESR = 23.259931079516917
```

[44]:
```
# (7) Tests de corrélation de Pearson et de Spearman
print("Pearson :")
print(stats.pearsonr(df_SHS["prop_livres_chapitres"].dropna(),␣
↪df_SHS["nb_ref"].dropna()))
print("")
print("Spearman :")
print(stats.spearmanr(df_SHS["prop_livres_chapitres"].dropna(),␣
↪df_SHS["nb_ref"].dropna()))
```

```
Pearson :
(0.04050192743832813, 0.021041105356744992)

Spearman :
SpearmanrResult(correlation=0.052308319071037175, pvalue=0.0028765538946782044)
```

5.2 Thèses de sciences dures

[45]:
```
# (1) Représentation de la proportion de livres et chapitres de livres cités␣
↪par thèse en sciences dures en fonction du nombre de références citées par␣
↪thèse
# ___(1a) Sélection des thèses de sciences dures
sciences_dures = ["V", "VI", "VII", "VIII", "IX", "X"]
df_sciences_dures = pd.DataFrame(columns = list(df_final.columns))
for i in sciences_dures:
    my_df = df_final[df_final["discipline"] == i]
    df_sciences_dures = pd.merge(df_sciences_dures, my_df, how = "outer")
prop_livres_chapitres = list(df_sciences_dures[df_sciences_dures["type_ref"]␣
↪== "livre"]["prop_type_ref"].values +␣
↪df_sciences_dures[df_sciences_dures["type_ref"] ==␣
↪"chapitre"]["prop_type_ref"].values)
nb_ref = list(df_sciences_dures[df_sciences_dures["type_ref"] ==␣
↪"livre"]["nb_ref"].values)
discipline = ["sciences_dures"] * len(nb_ref)
df_sciences_dures = pd.DataFrame({"prop_livres_chapitres":␣
↪prop_livres_chapitres, "nb_ref": nb_ref, "discipline": discipline})

# ___(1b) Représentation en scatter plot, la ligne rouge représentant la␣
↪droite de régression
model_sciences_dures = ols("prop_livres_chapitres ~ nb_ref", data =␣
↪df_sciences_dures).fit()
```

```
coeffs_sciences_dures = model_sciences_dures.params
ic_sciences_dures, slope_sciences_dures = coeffs_sciences_dures
fig, ax = plt.subplots(figsize = (17.5/2.54, 9/2.54))
sns.scatterplot(x = "nb_ref", y = "prop_livres_chapitres", data =␣
↪df_sciences_dures, alpha = 0.1, color = "black", s = 25)
ax.axline(xy1 = (0, ic_sciences_dures), slope = slope_sciences_dures, color =␣
↪"red")
ax.set_ylim(0, 100)
ax.set_xlabel("Nombre de références par thèse", labelpad = 8)
ax.set_ylabel("Pourcentage de livres et chapitres de livres", labelpad = 8)
ax.spines[["top", "right"]].set_visible(False)
plt.show()
```

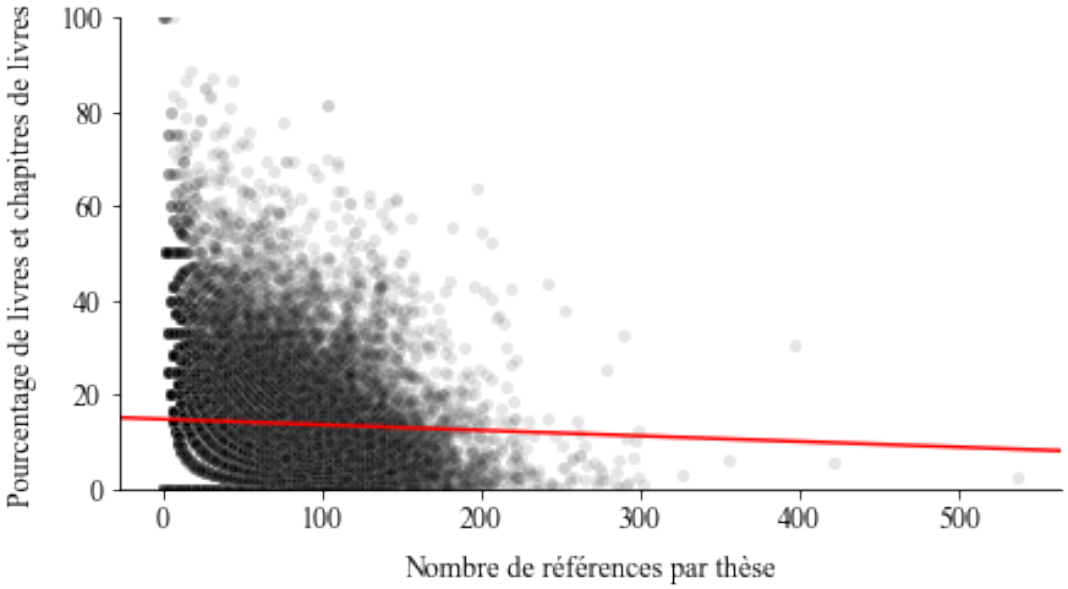

[46]:
```
# (2) Affichage de l'équation de la droite de régression :
print("y = " + str(ic_sciences_dures) + " + " + str(slope_sciences_dures) +␣
↪"x")
```

```
y = 14.80058367648076 + -0.011882279487390686x
```

[47]:
```
# (3) Test de la normalité de la distribution des données des deux variables␣
↪analysées
test_shapiro_1 = stats.shapiro(df_sciences_dures["prop_livres_chapitres"])
test_shapiro_2 = stats.shapiro(df_sciences_dures["nb_ref"])
plt.rc("font", family = "Times New Roman", size = 12)
fig, ax = plt.subplots(nrows = 1, ncols = 2, figsize = (24/2.54, 9/2.54))
ax[0].hist(df_sciences_dures["prop_livres_chapitres"], bins = 10)
ax[0].spines[["right", "top"]].set_visible(False)
ax[0].set_title("W = " + str(round(test_shapiro_1[0], 2)) + " ; P = " +␣
↪str(test_shapiro_1[1]))
```

```
ax[0].set_xlabel("Pourcentage de livres et chapitres cités par thèse",␣
 ↪labelpad = 8)
ax[0].set_ylabel("Fréquence", labelpad = 8)
ax[1].hist(df_sciences_dures["nb_ref"], bins = 10)
ax[1].spines[["right", "top"]].set_visible(False)
ax[1].set_title("W = " + str(round(test_shapiro_2[0], 2)) + " ; P = " +␣
 ↪str(test_shapiro_2[1]))
ax[1].set_xlabel("Nombre de références par thèse", labelpad = 8)
ax[1].set_ylabel("Fréquence", labelpad = 8)
plt.subplots_adjust(wspace = 0.30)
plt.show()
```

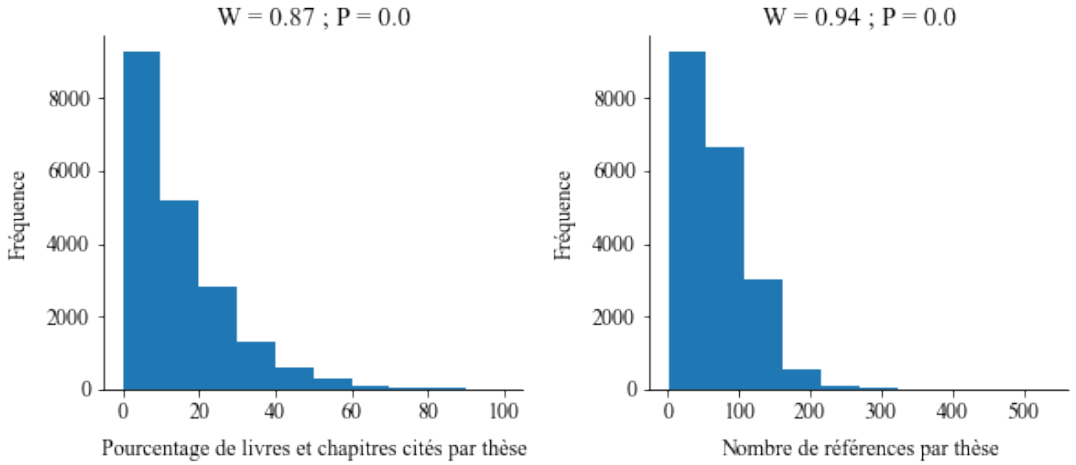

[48]:
```
# (4) Affichage des paramètres du modèle
print(model_sciences_dures.summary())
```

```
                            OLS Regression Results
==============================================================================
=
Dep. Variable:     prop_livres_chapitres   R-squared:
0.002
Model:                               OLS   Adj. R-squared:
0.002
Method:                    Least Squares   F-statistic:
35.67
Date:                   Sat, 10 Sep 2022   Prob (F-statistic):
2.38e-09
Time:                           11:07:03   Log-Likelihood:
-78627.
No. Observations:                  19615   AIC:
1.573e+05
Df Residuals:                      19613   BIC:
1.573e+05
Df Model:                              1
Covariance Type:               nonrobust
==============================================================================
```

```
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept     14.8006      0.161     92.164      0.000      14.486      15.115
nb_ref        -0.0119      0.002     -5.972      0.000      -0.016      -0.008
==============================================================================
Omnibus:                     5054.250   Durbin-Watson:                   1.702
Prob(Omnibus):                  0.000   Jarque-Bera (JB):            12742.355
Skew:                           1.412   Prob(JB):                         0.00
Kurtosis:                       5.759   Cond. No.                         136.
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly
specified.
```

[49]:
```
# (5) Calcul de l'erreur standard résiduelle
print("ESR = " + str(erreur_standard_residuelle(model_sciences_dures,␣
 ↪len(df_sciences_dures["prop_livres_chapitres"].index))))
```

```
ESR = 13.324698101939783
```

[50]:
```
# (6) Tests de corrélation de Pearson et de Spearman
print("Pearson :")
print(stats.pearsonr(df_sciences_dures["prop_livres_chapitres"].dropna(),␣
 ↪df_sciences_dures["nb_ref"].dropna()))
print("")
print("Spearman :")
print(stats.spearmanr(df_sciences_dures["prop_livres_chapitres"].dropna(),␣
 ↪df_sciences_dures["nb_ref"].dropna()))
```

```
Pearson :
(-0.04260592596936459, 2.380665738031805e-09)

Spearman :
SpearmanrResult(correlation=0.09830164150640021, pvalue=2.546745904878555e-43)
```